

# Evaluaciones Agropecuarias Municipales (EVA)

Juan David Colón, Alan Tapias Melgarejo, Santiago Andres Cardona Rendon, Juan Martinez Parra, Luis Tamara Velasquez.

Programación para la ciencia de datos,

Ciencia de datos

## Problema/objetivo

Las Evaluaciones Agropecuarias Municipales (EVA) constituyen una fuente fundamental de información para el análisis y seguimiento de la actividad agrícola en Colombia, ya que recopilan datos relacionados con la producción, el rendimiento y las áreas sembradas y cosechadas de diversos cultivos a nivel municipal. Sin embargo, el gran volumen de registros, la diversidad de variables y la posible presencia de datos faltantes, valores atípicos o inconsistencias pueden dificultar su interpretación y aprovechamiento. Por ello, este proyecto tiene como objetivo realizar un análisis exploratorio y de calidad de datos que permita caracterizar las variables numéricas y categóricas del conjunto EVA, evaluar la consistencia de la información, identificar oportunidades de mejora y generar hallazgos relevantes que contribuyan a una mejor comprensión de la producción agropecuaria en Colombia y sirvan como base para futuros procesos de análisis y toma de decisiones en el sector.



## Data

**Fuente de datos:** El conjunto de datos utilizado corresponde a las **Evaluaciones Agropecuarias Municipales (EVA)** de Colombia, una base de información oficial que recopila estadísticas relacionadas con la actividad agrícola a nivel municipal. El dataset contiene registros sobre producción agrícola para el periodo 2006–2018 e incluye información de los 32 departamentos y más de 1.000 municipios del país.

| VARIABLE                                      | TIPO    | DESCRIPCIÓN CORTA                 |
|-----------------------------------------------|---------|-----------------------------------|
| CÓD. DEP.                                     | int64   | Código del departamento           |
| DEPARTAMENTO                                  | str     | Nombre del departamento           |
| CÓD. MUN.                                     | str     | Código del municipio              |
| MUNICIPIO                                     | str     | Nombre del municipio              |
| GRUPO DE CULTIVO                              | str     | Clasificación general del cultivo |
| SUBGRUPO DE CULTIVO                           | str     | Subcategoría del cultivo          |
| CULTIVO                                       | str     | Nombre del cultivo                |
| DESAGREGACIÓN REGIONAL Y/O SISTEMA PRODUCTIVO | str     | Sistema o región productiva       |
| AÑO                                           | str     | Año del registro                  |
| PERIODO                                       | str     | Periodo productivo                |
| Área Sembrada (ha)                            | str     | Área sembrada en hectáreas        |
| Área Cosechada (ha)                           | str     | Área cosechada en hectáreas       |
| Producción (t)                                | str     | Producción en toneladas           |
| Rendimiento (t/ha)                            | float64 | Producción por hectárea           |
| ESTADO FISICO PRODUCCION                      | str     | Estado físico del producto        |
| NOMBRE CIENTIFICO                             | str     | Nombre científico del cultivo     |

## Métodos/modelos

Herramientas utilizadas: Lenguaje, Python (Quarto),  
Librerías Pandas: NumPy, Matplotlib/Seaborn



Pipeline de análisis

1.Carga del dataset, Lectura del archivo con Pandas, revisión de dimensiones, tipos de datos y conteo de nulos por columna.

2.Análisis de completitud Cálculo del porcentaje de nulos por variable. Se identificaron dos campos críticos: Rendimiento (t/ha) con 1.67% de nulos y Nombre Científico con 1.39%.

3.Identificación de oportunidades de mejora Revisión sistemática de problemas de calidad: nombres de columnas con saltos de línea, números almacenados como texto con separadores de miles, códigos geográficos no compatibles con DIVIPOLA, y la inconsistencia agronómica de 13,634 filas donde Área Cosechada > Área Sembrada.

4.Análisis estadístico descriptivo: Variables numéricas Cálculo de medidas de tendencia central, dispersión (desviación estándar, varianza), medidas de forma para las 4 variables numéricas del dataset. Complementado con histogramas y boxplots para detectar la distribución fuertemente sesgada a la derecha.

5.Análisis de frecuencias: Variables categóricas Conteo de valores únicos por cada una de las 13 variables categóricas, cálculo de modas y tablas de frecuencia para identificar las categorías dominantes



Universidad  
Tecnológica  
de Bolívar





Escuela de  
Transformación  
Digital

## Resultados


Se identificó una alta completitud de la información, con un 99,8% de datos disponibles en los 206.068 registros analizados. La mayoría de las variables presentan pocos valores faltantes, lo que permite realizar análisis estadísticos confiables y representativos del sector agrícola colombiano.

| REGISTROS | VARIABLES | COMPLETITUD |
|-----------|-----------|-------------|
| 206,068   | 17        | 99.8%       |

Las variables de producción agrícola presentan distribuciones altamente asimétricas y valores atípicos, especialmente en la variable Producción.



Asimismo, se observó una gran diversidad territorial y productiva reflejada en la alta cardinalidad de municipios, En cultivo la categoría maíz fue la mas frecuente.



## impacto y límites

### Impacto

- El análisis cubre **206,068 registros** de producción agrícola colombiana con un 99.8% de completitud, lo que permite generar conclusiones estadísticas robustas a escala nacional.
- El perfil estadístico de las 4 variables numéricas (alta asimetría) revela que la producción agrícola es altamente concentrada en pocos municipios.

### Límites

- Los datos solo abarcan **13 años** (aprox. 2006–2018), lo que limita el análisis de tendencias recientes.
- El 1.67% de nulos en Rendimiento (t/ha) y el 1.39% en Nombre Científico pueden sesgar comparaciones entre cultivos.
- El dataset no incluye variables socioeconómicas (precio, ingresos del agricultor), lo que impide análisis de rentabilidad

## Etica/privacidad

- El dataset es de **fuentes públicas**, por lo que no contiene información personal identificable ni sensible.
- No existe riesgo de re-identificación de individuos, ya que la granularidad mínima es el **municipio**.
- Sin embargo, el uso de estos datos para decisiones de política pública exige transparencia metodológica: las inconsistencias detectadas (e.g., áreas cosechadas > sembradas) deben comunicarse explícitamente antes de usar el análisis como base de decisiones.
- La sobrerepresentación de ciertos departamentos o cultivos en los datos originales puede trasladarse a los resultados si no se pondera adecuadamente

## Futuro del proyecto

- Gestión de inconsistencias:** Crear un flag de calidad para las 13,634 filas con área cosechada > sembrada e investigar su origen (error de captura vs. dato real).
- Separación temporal:** Desagregar la columna PERIODO en columnas año y semestre para habilitar análisis de series de tiempo.
- Integración con variables externas:** Cruzar el dataset con datos climáticos, precios de mercado e índices de pobreza municipal para construir modelos predictivos de producción.
- Modelos de predicción:** Entrenar modelos de regresión para estimar rendimiento por cultivo/región y apoyar la toma de decisiones agrícolas

